



开源社
kaiyuanshe



COSCon'25

第十届中国开源年会

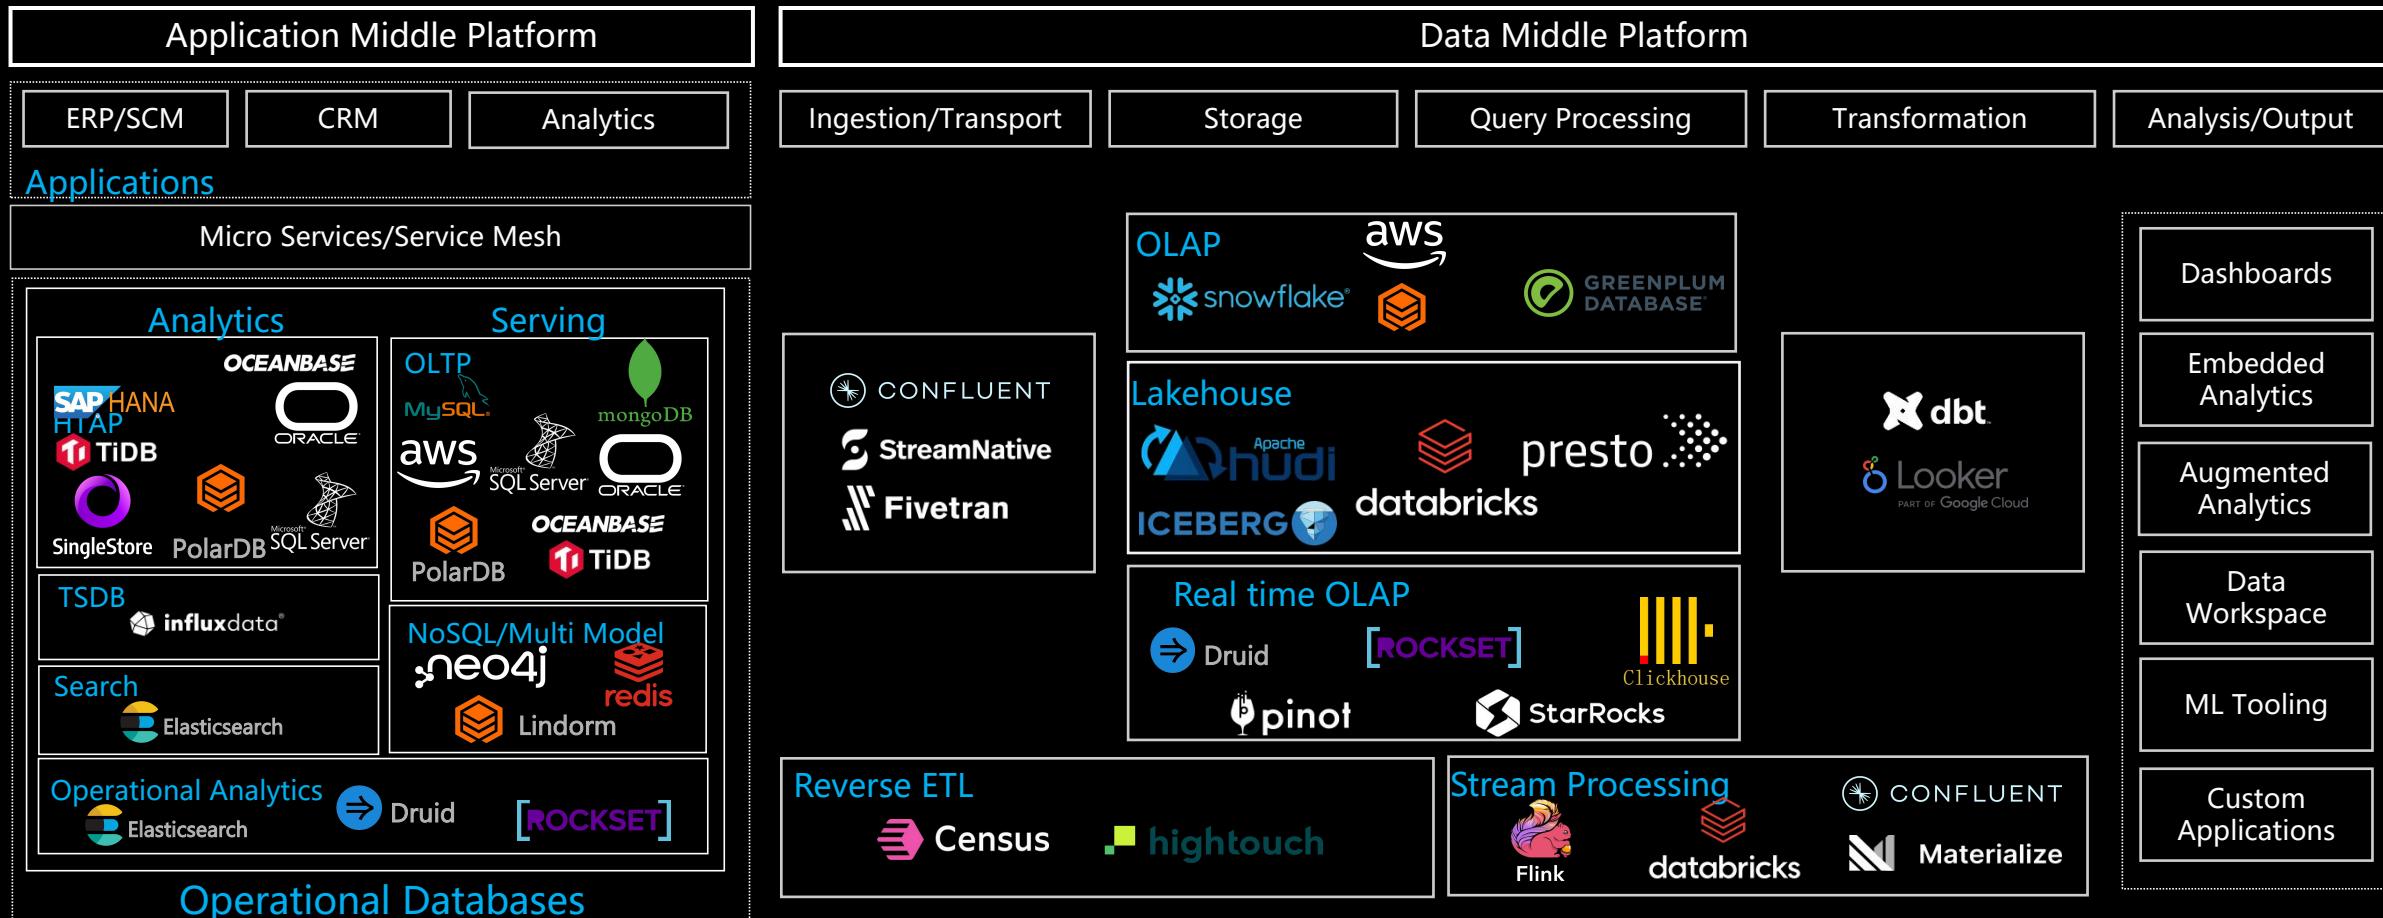
众智开源 | Open Source, Open Intelligence

回顾与展望
——构建大模型时代的核心数据基础设施

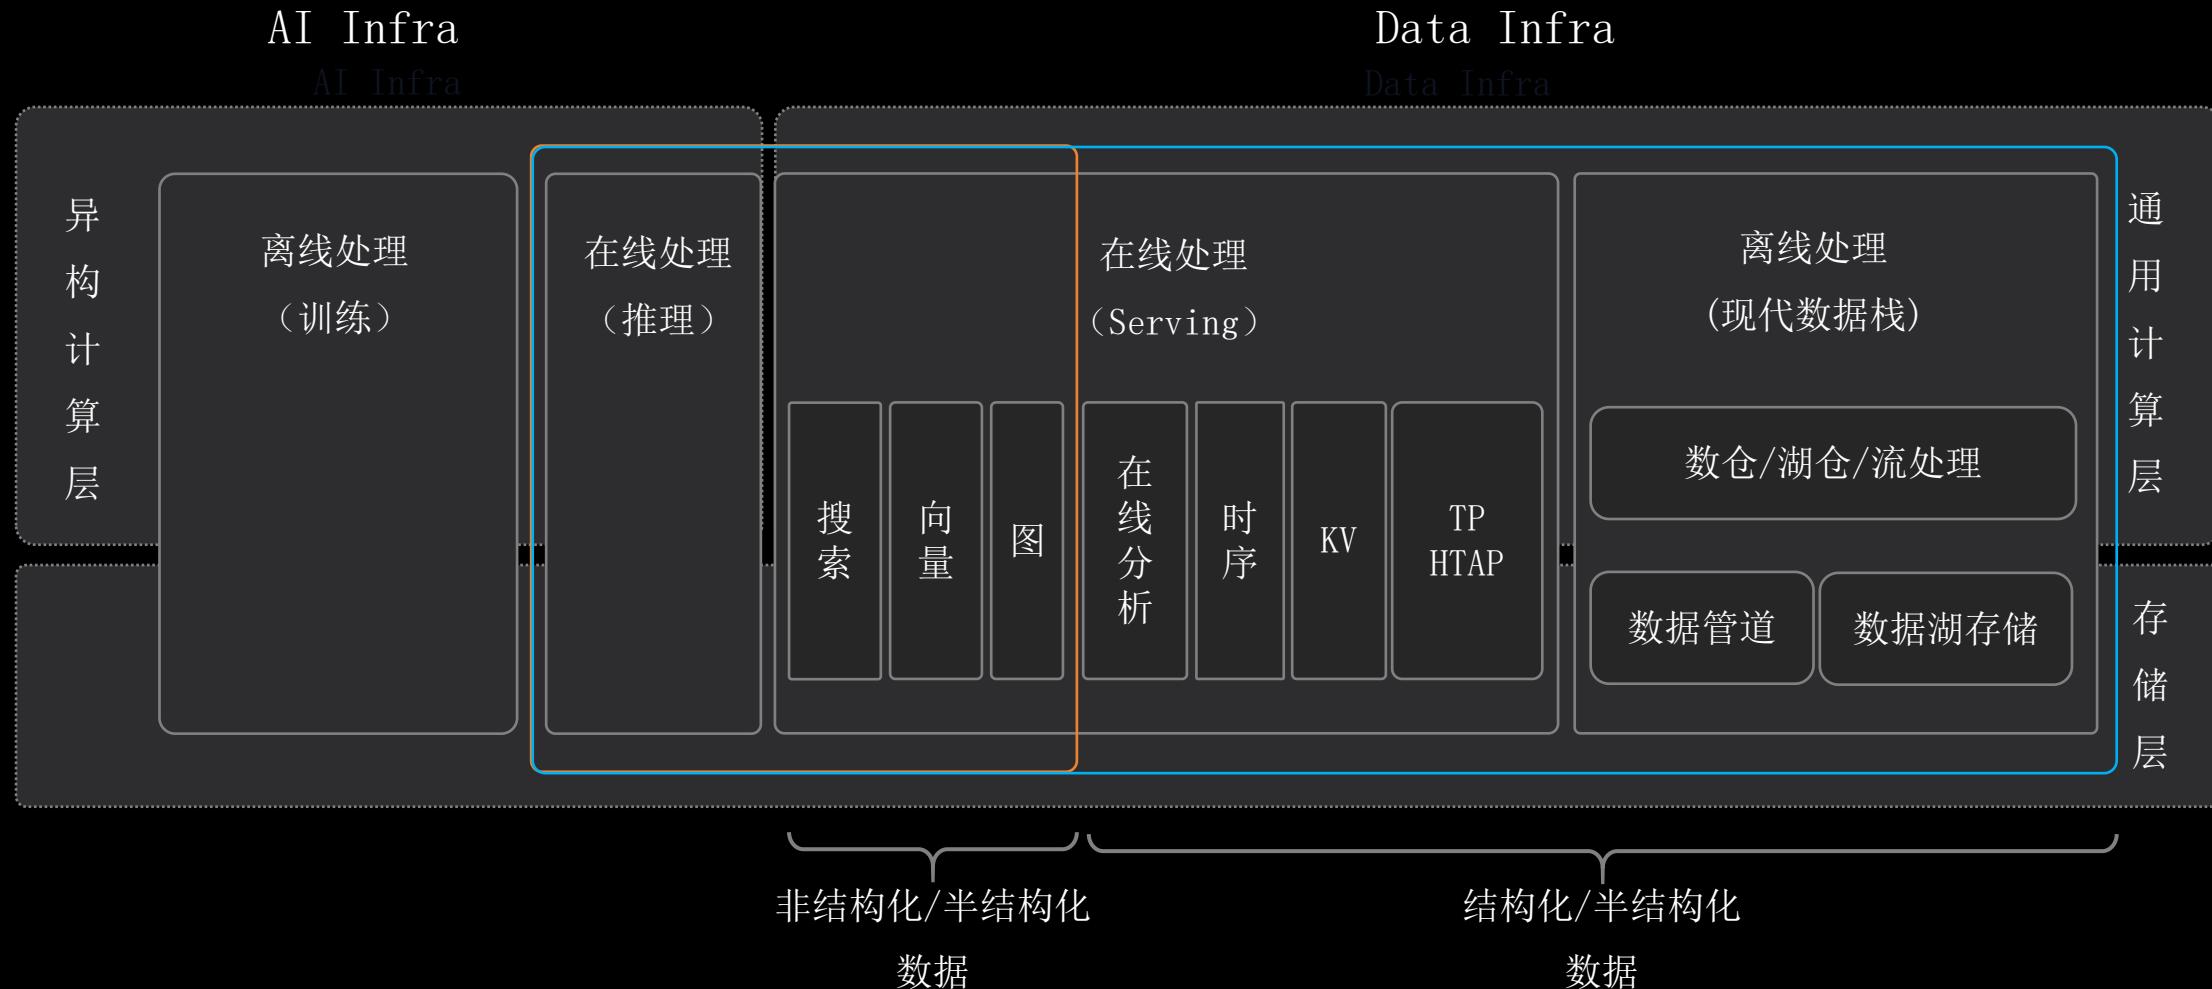
张颖峰@RAGFlow



Data Infra 总览



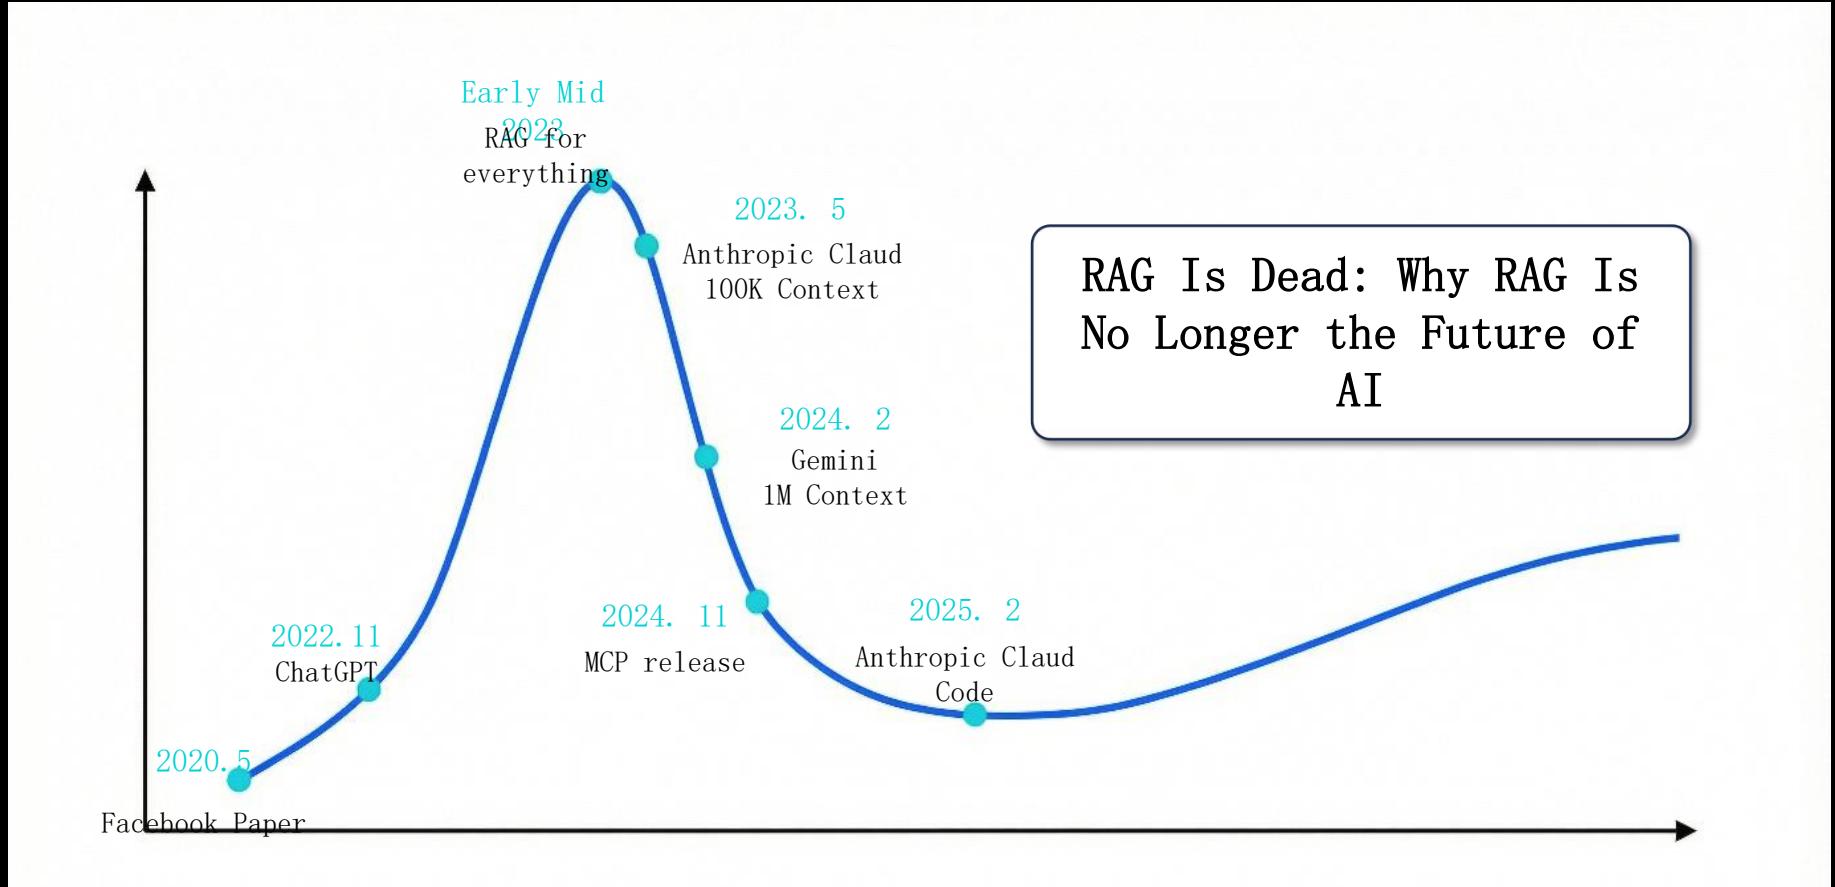
AI Infra 和 Data Infra



RAG Is Dead



- RAG 效果不好
- Long Context 足够了
- 有 Agents 不需要 RAG
- Memory 比 RAG 效果好



向 LLM 提供输入的四种模式



- 只依靠 LLM 的 Context
- 借助于 KV Cache
- 无需索引的搜索 => Grep
- 基于搜索引擎 => RAG

82 x \$

12 x

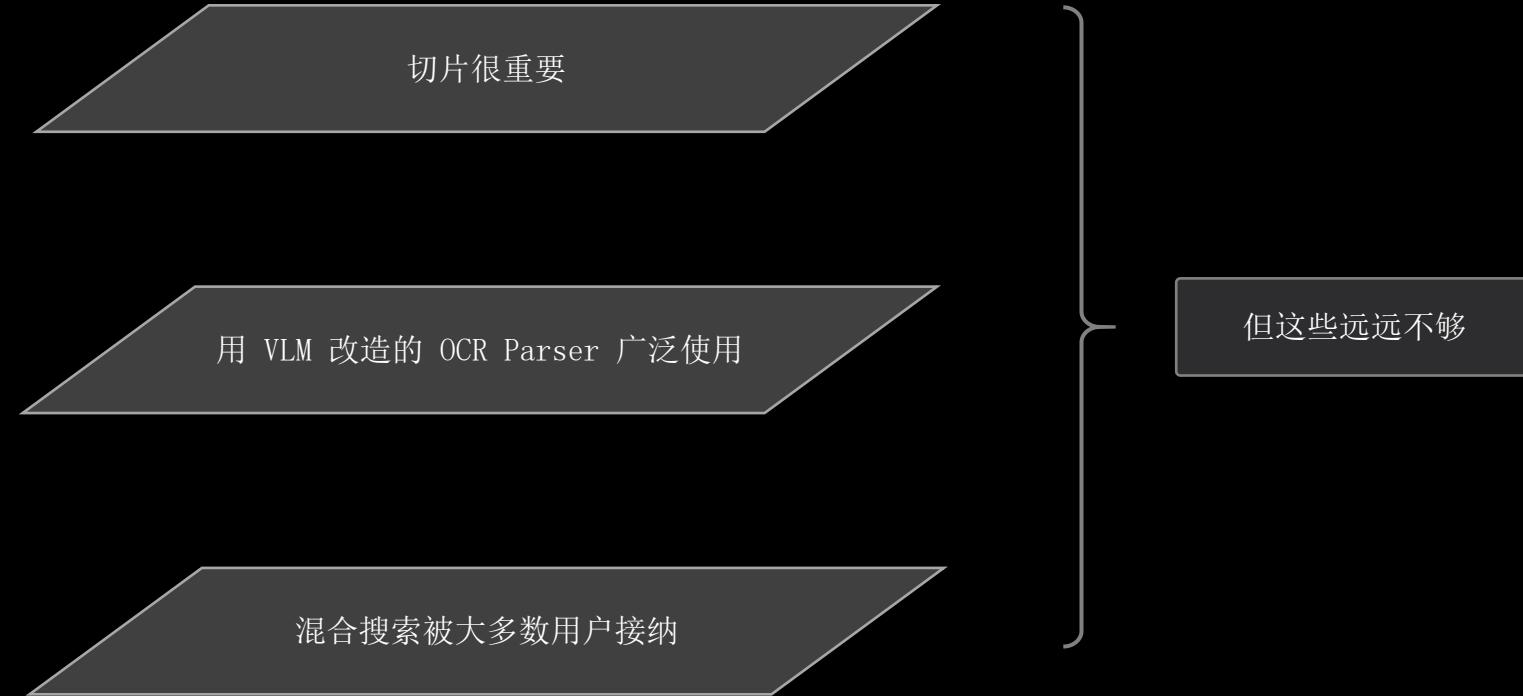
7 x \$

- 过长上下文导致成本激增和理解力下降

数据类型	Token消耗
单张技术图表	~1,000 tokens
典型代码库	数千万 tokens
企业级仓库	数亿 tokens
1,000页文档	600,000 tokens

- 为什么 Grep 不能满足要求
- RAG 就是 Context Engineering 1.0

过去一年 RAG 发展的共识



RAG 的痛点还有解么？



- 各种方案都是
- Chunk 很难切得准
 - Search 和 Retrieval 的矛盾
 - 性价比很低的 GraphRAG

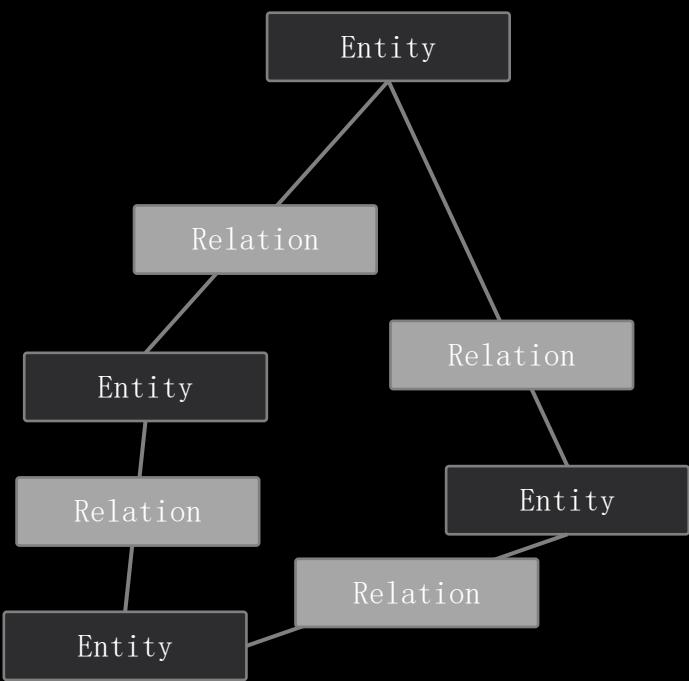
Search: 扫描和定位，需要小块以提高语义匹配精度

Retrieval: 阅读和理解，需要大块以提供完整上下文

RAG 的痛点应该如何解



Long Context RAG



借助于 LLM 弥补语义鸿沟

RAW Text

Indexing

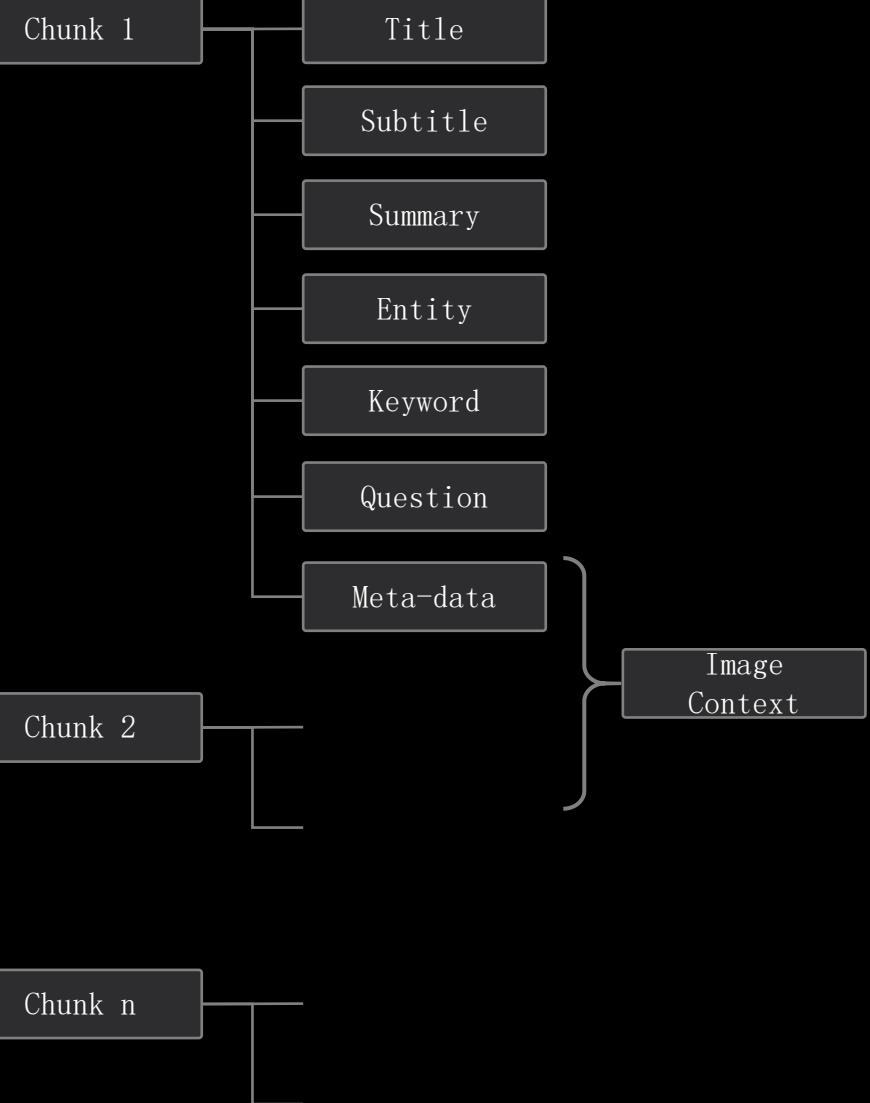


Graph
Structure

Tree
Structure

Retrieval

树/图结合

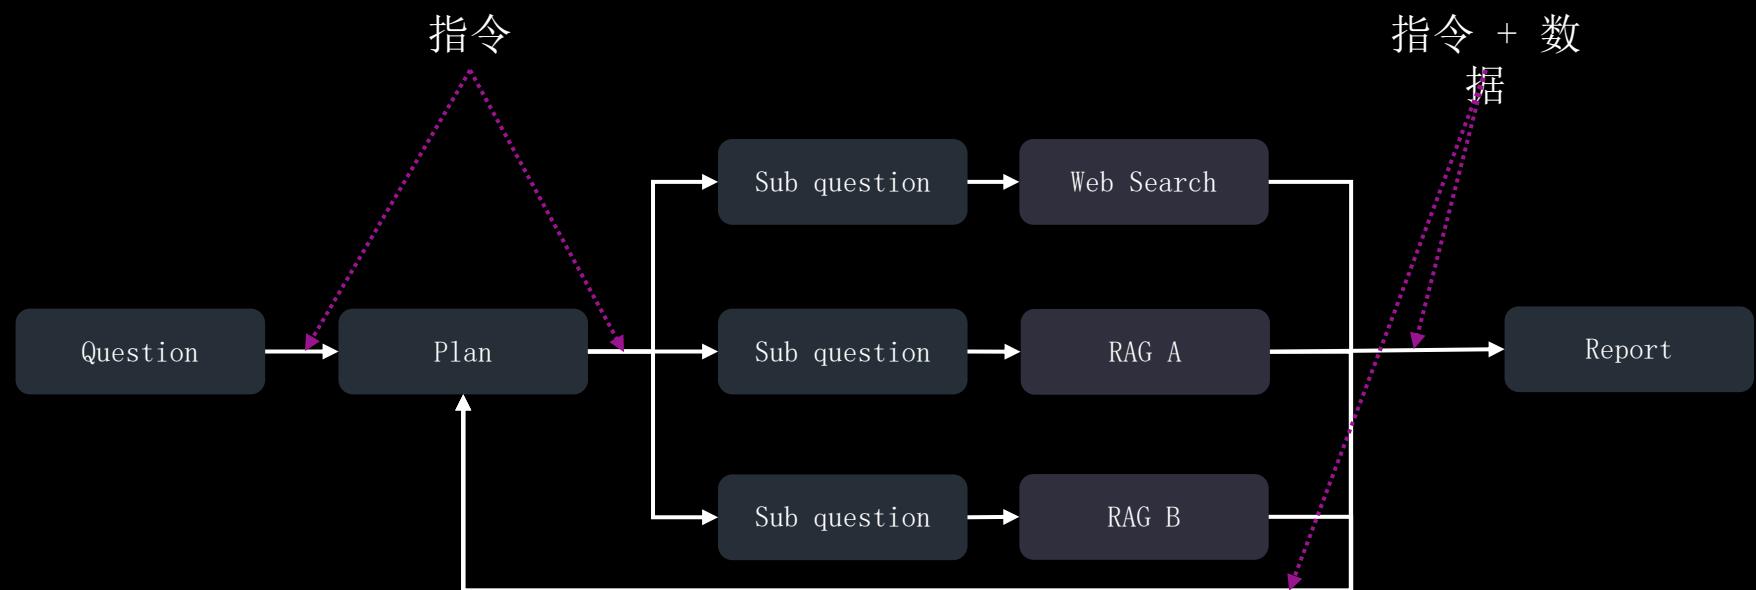


从 RAG 到 Agent

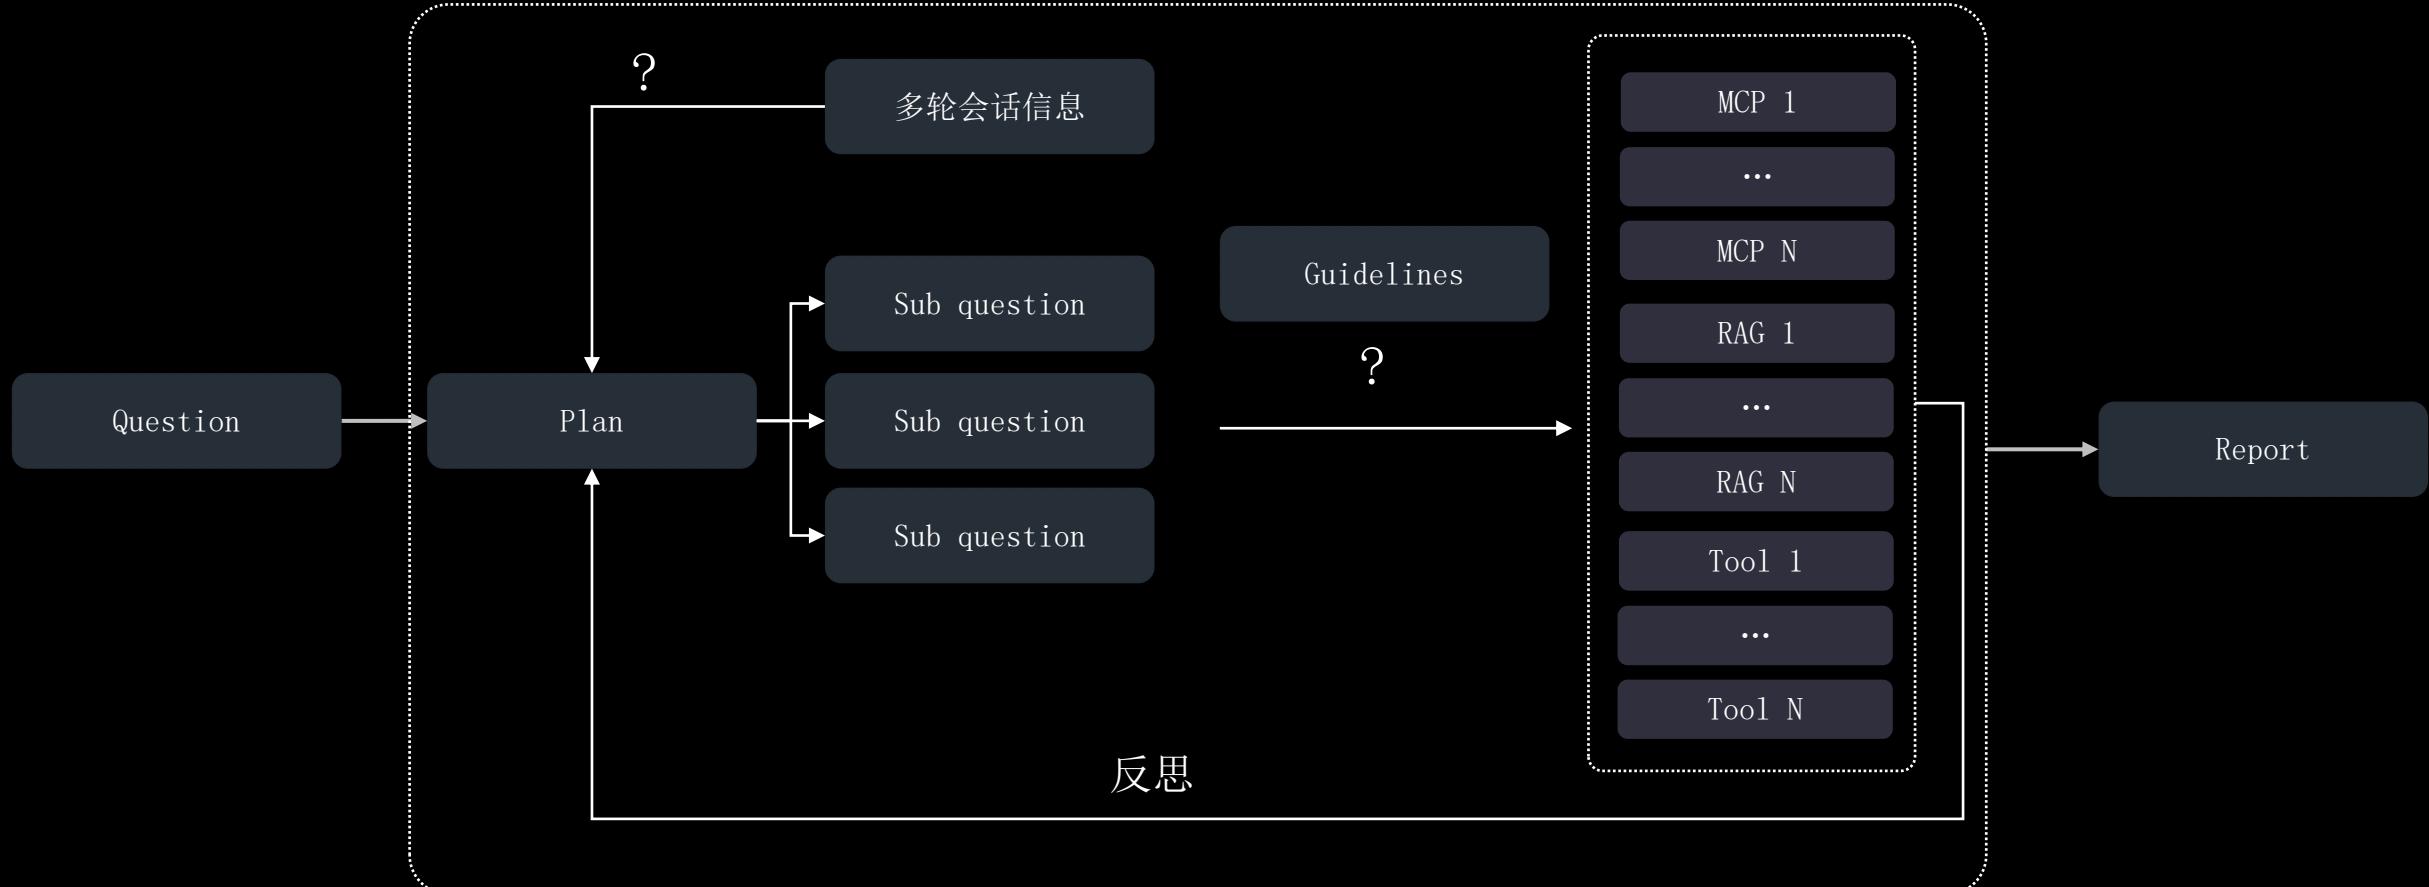


Context = 指令 + 数据

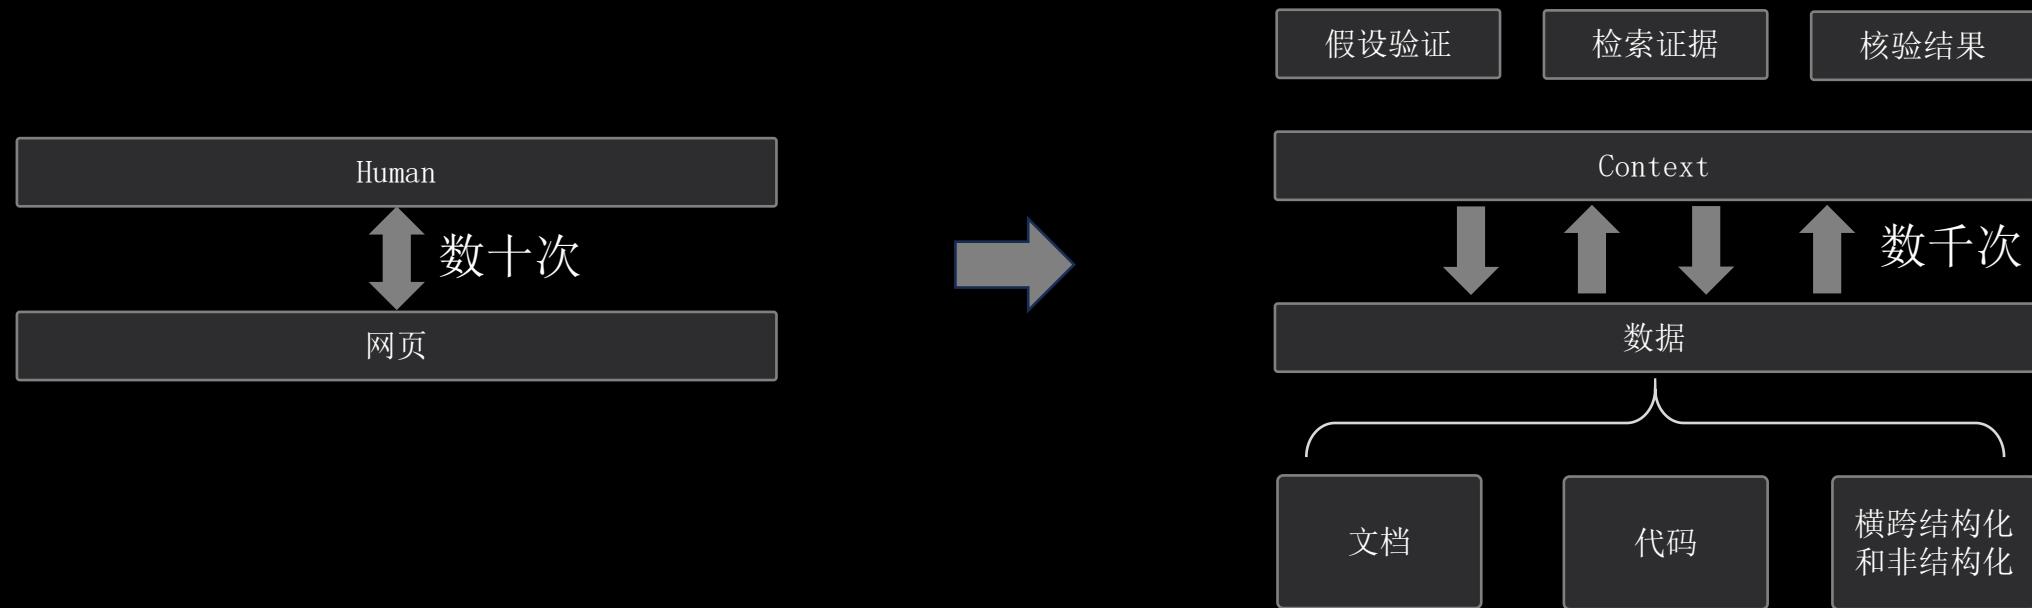
- 为什么需要 Agent
因为 LLM 一次只能干一件事
- 为什么 RAG/Agent 密不可分
反思无处不在
- 一切都是为了 Context



指令也不能无脑填充



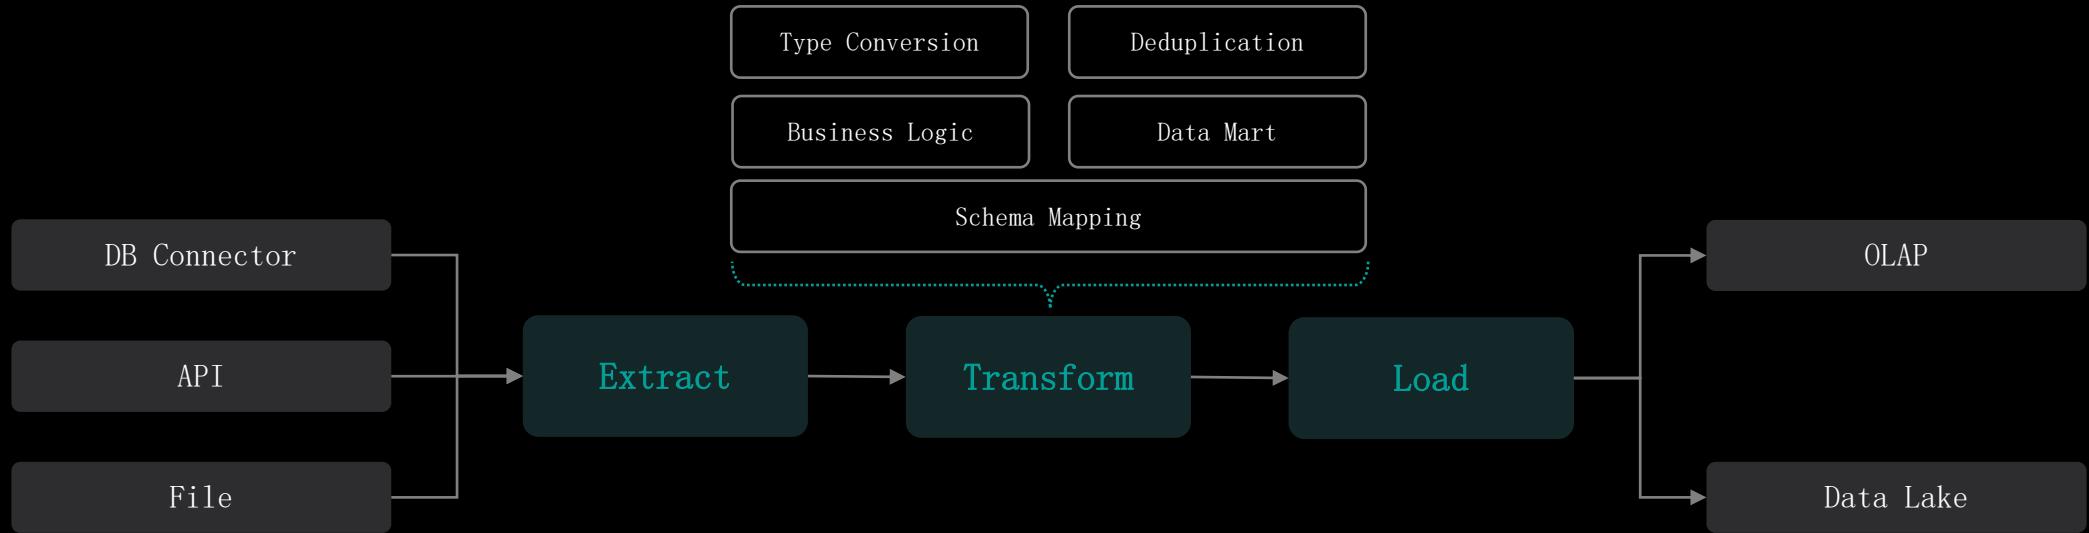
为什么 Retrieval 对 Agents 如此重要



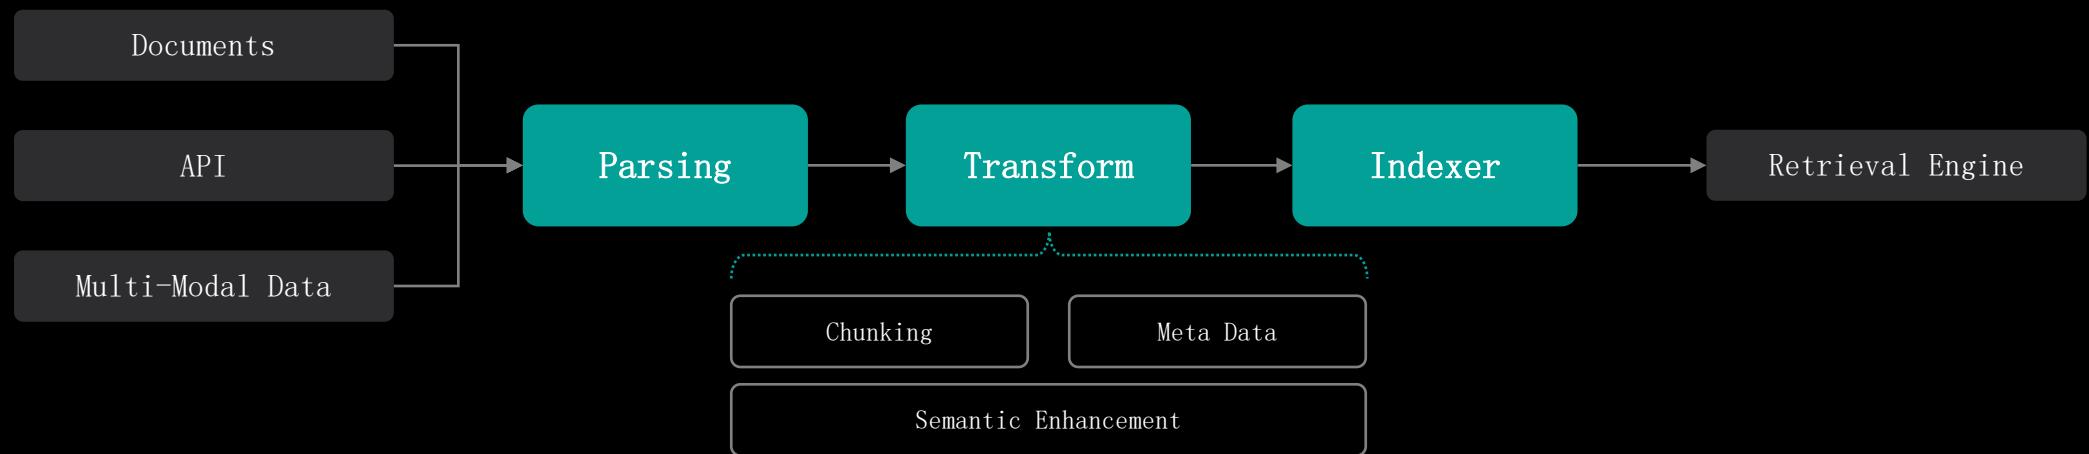
Agent Context 需要什么样的数据底座



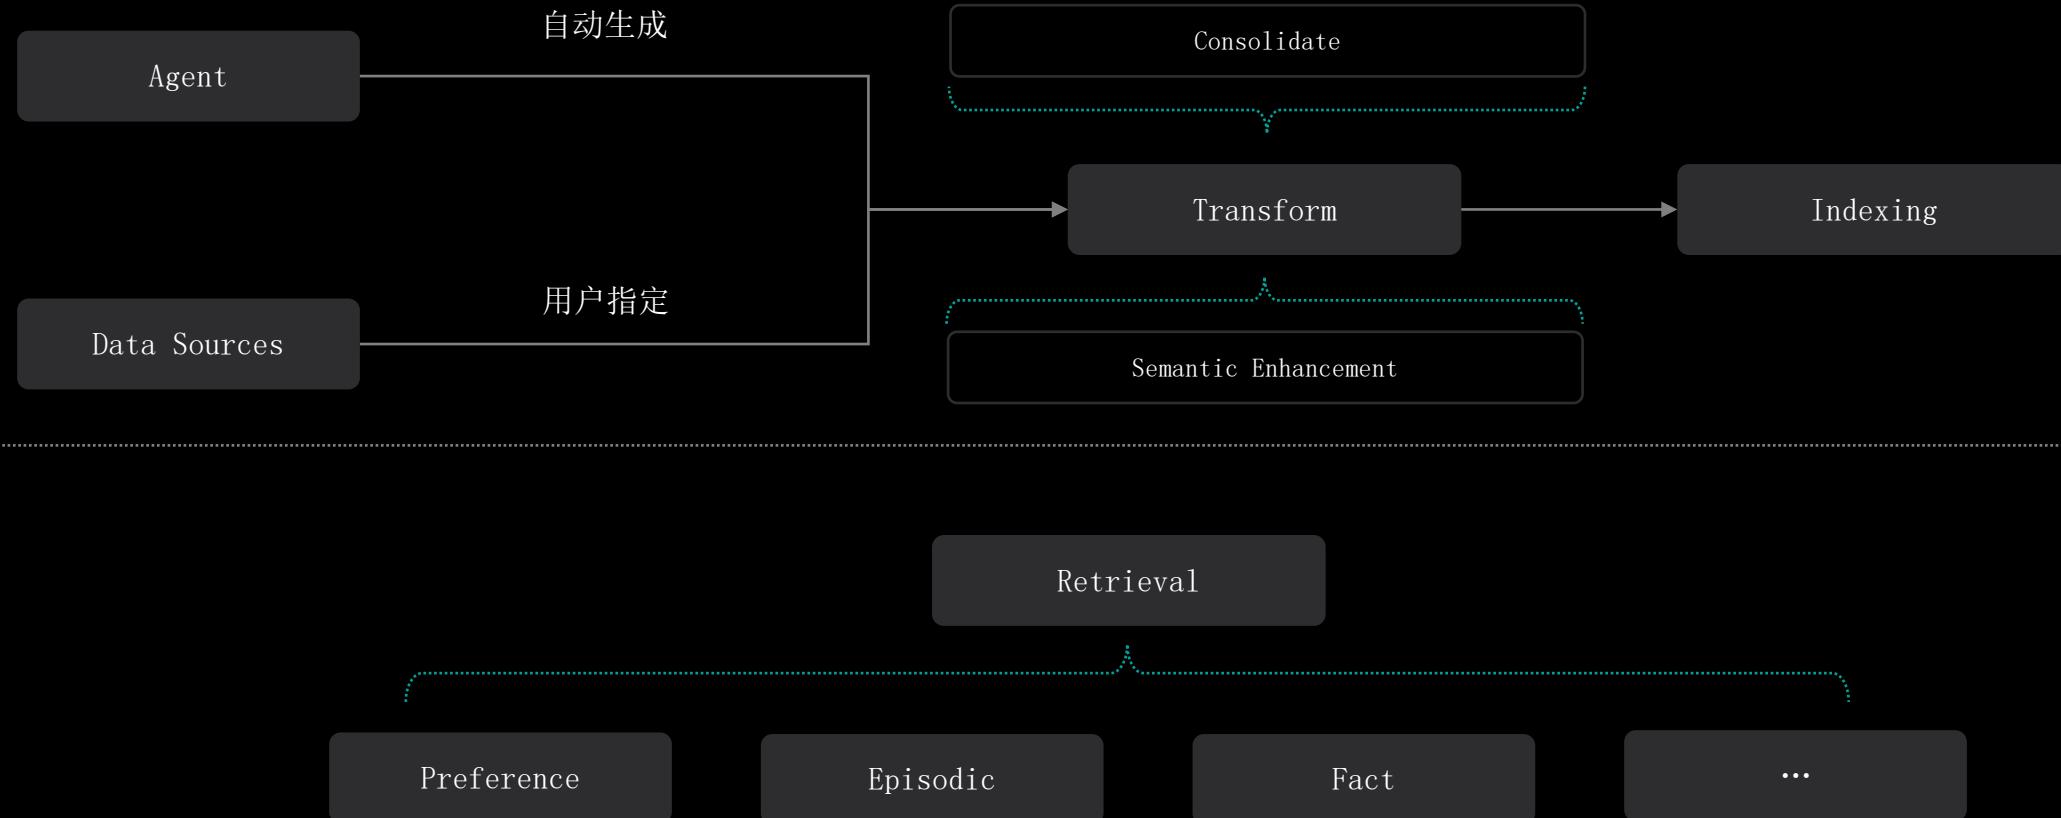
从 ETL 到 PTI



VS



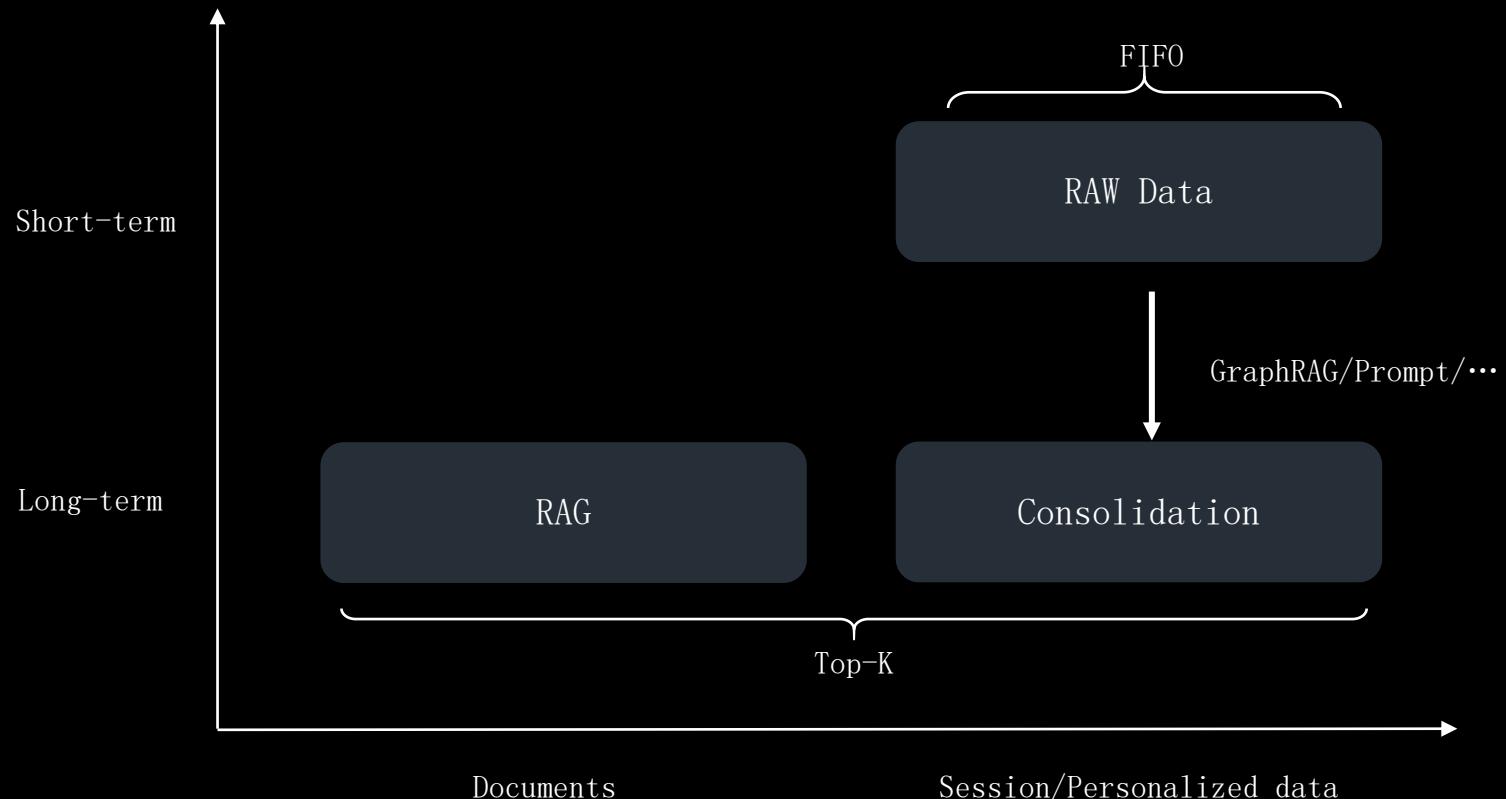
Memory 和 RAG——区别仅在于保存的数据



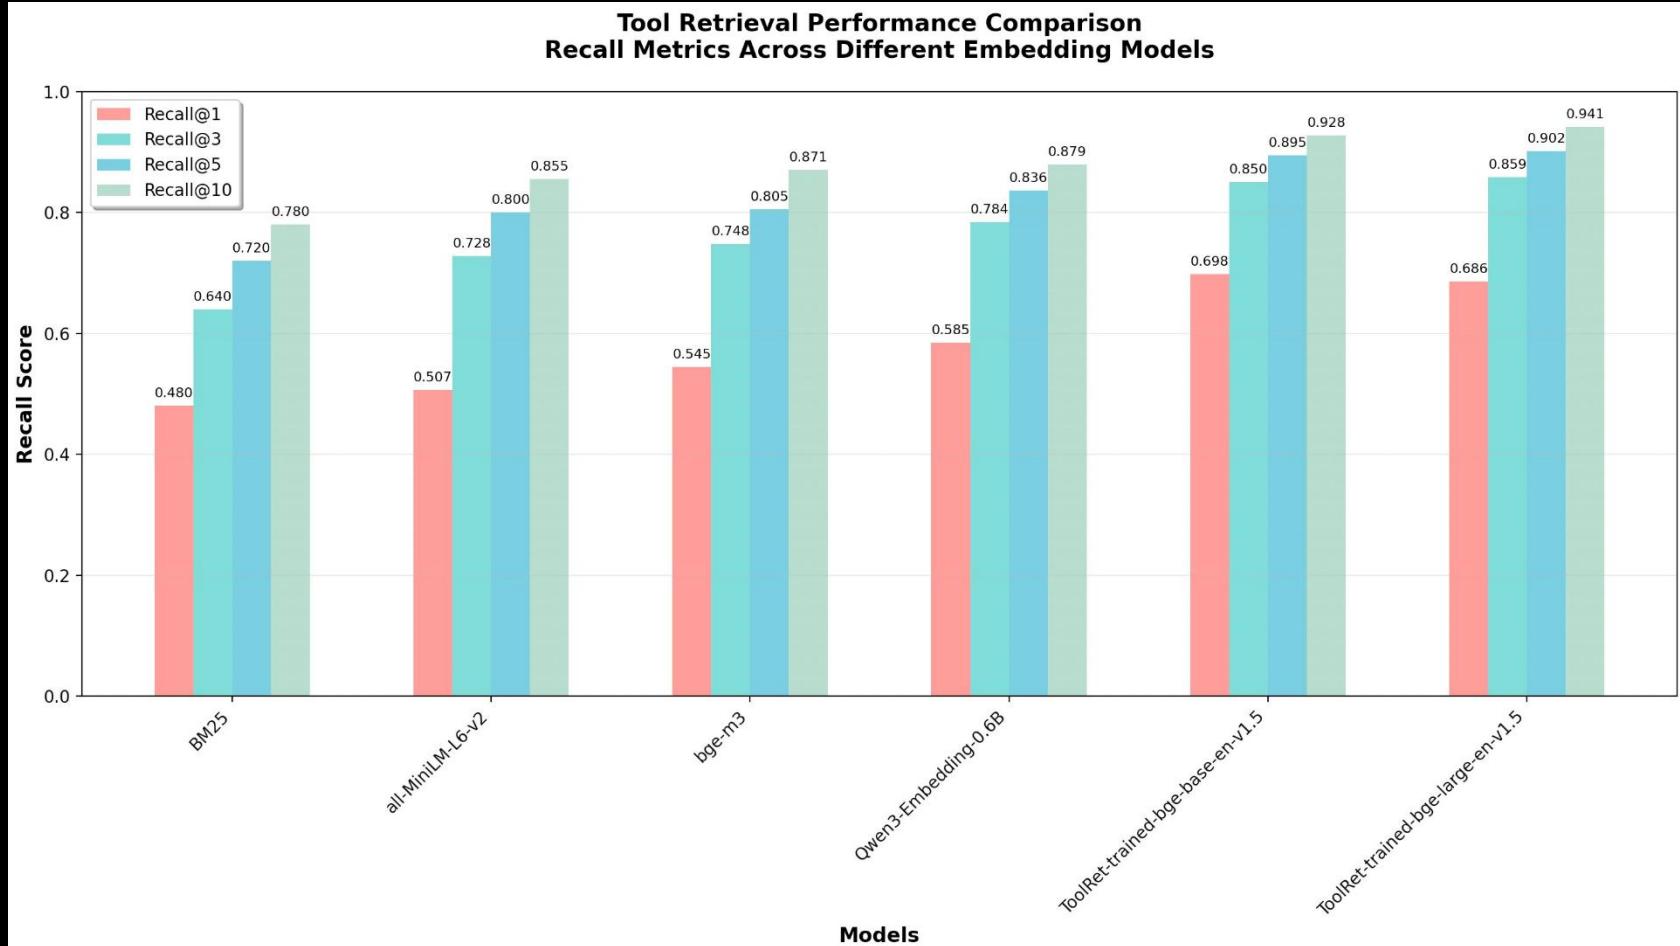
记忆可以成为独立平台么？



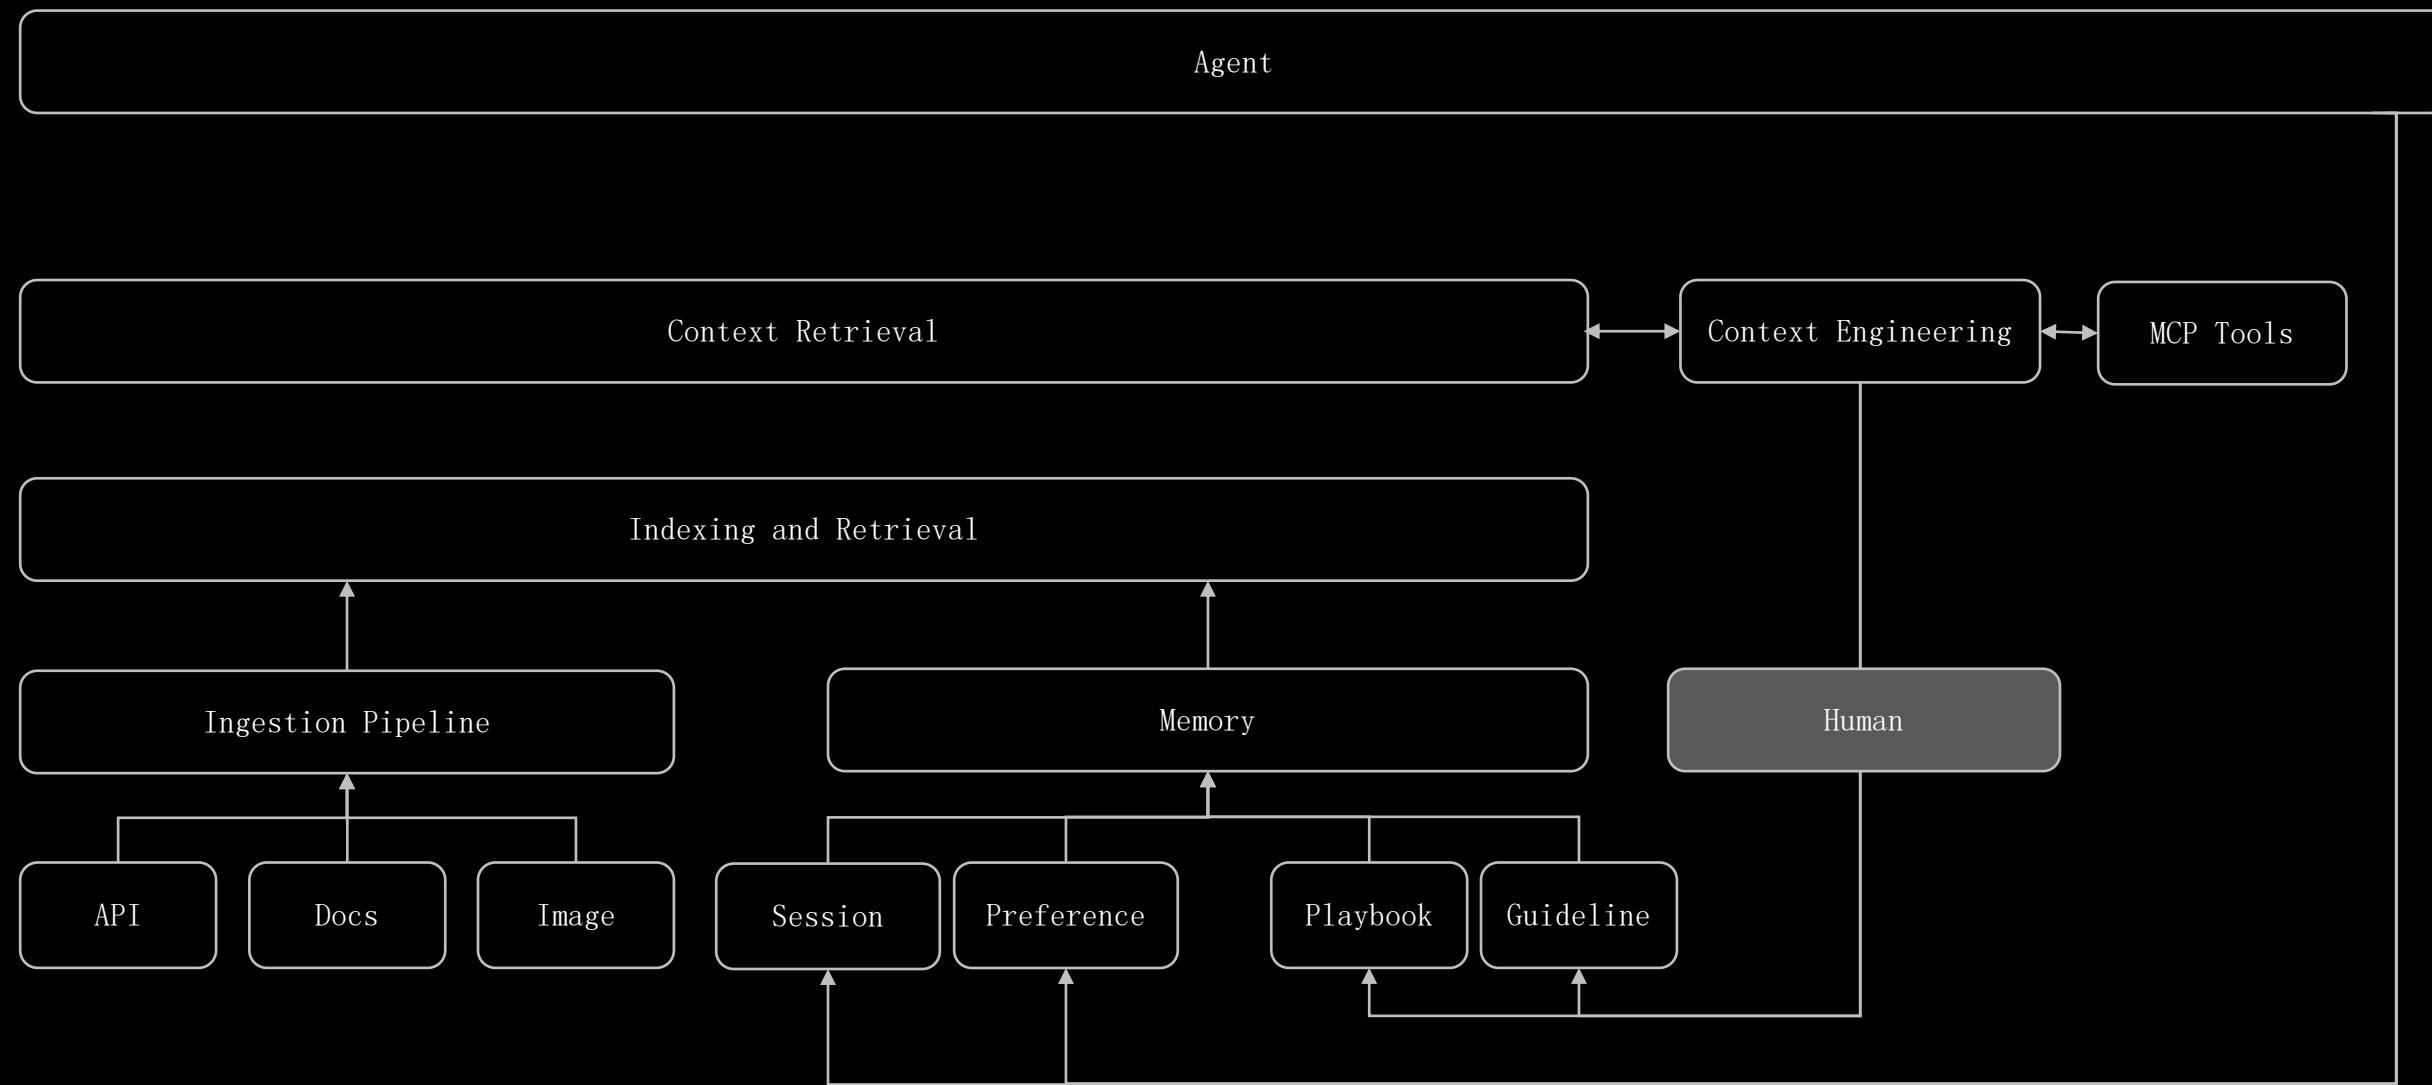
当下的 Memory 定义



Tools 也是需要 Retrieval 的



Tools 和 Guideline



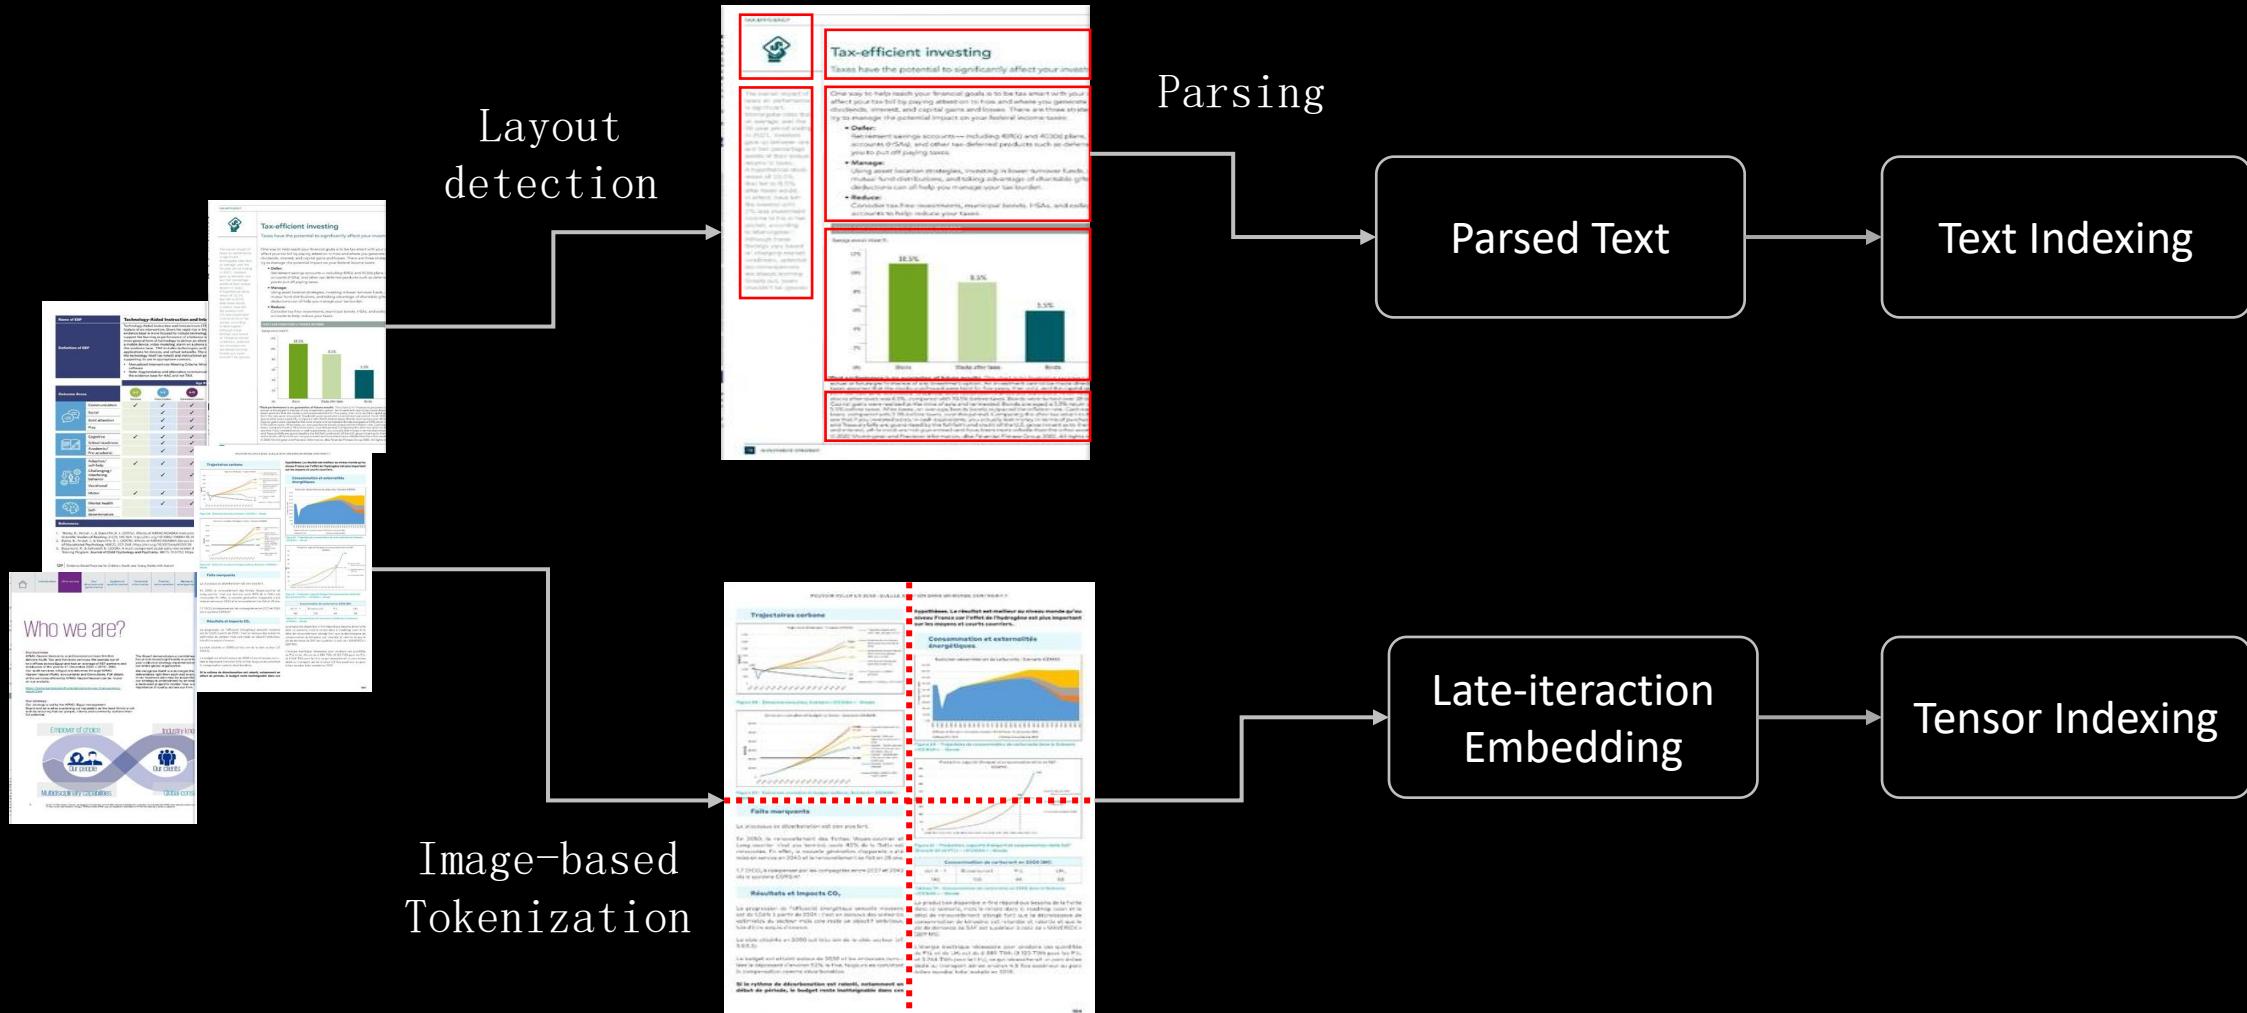
企业 AI 落地的下一个范式转移



维度	Context Engineering (现状)	Context Platform (未来)
Context 创建	FDE 完成	大多自动化
Context 组装	在 Workflow 当中进行 Prompt 硬编码	Context Retrieval
Context 维护	Vendor 手动维护	客户自主维护

- Context 的“产品化”将是解锁下一代AI应用的关键
- 从 RAG 到 Memory 到 Context，代表了 LLM 和 Agent 应用范式的成熟

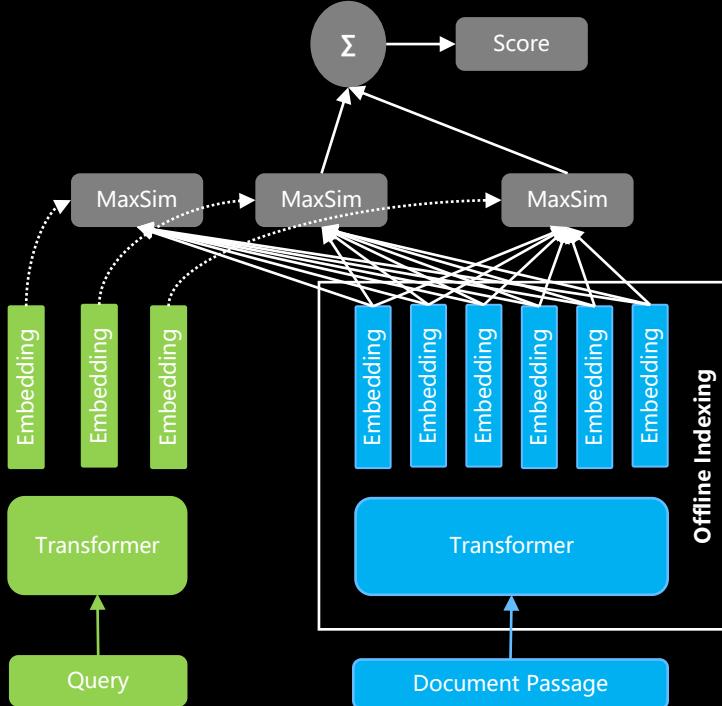
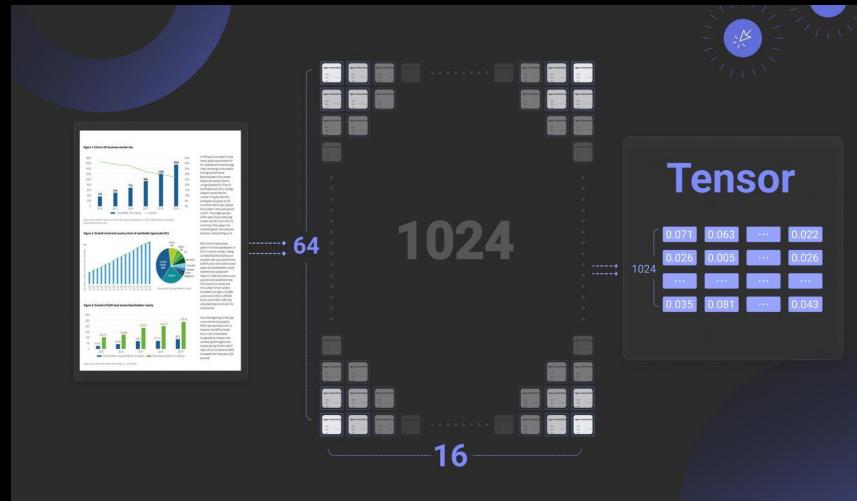
关于多模态和跨模态 Retrieval 的那些事情



关于多模态和跨模态 Retrieval 的那些事情



单向量还是多向量 (Late Interaction)



Google DeepMind

On the Theoretical Limitations of Embedding-Based Retrieval

Orion Weller^{*,1,2}, Michael Boratko¹, Iftekhar Naim¹ and Jinhyuk Lee¹

¹Google DeepMind, ²Johns Hopkins University

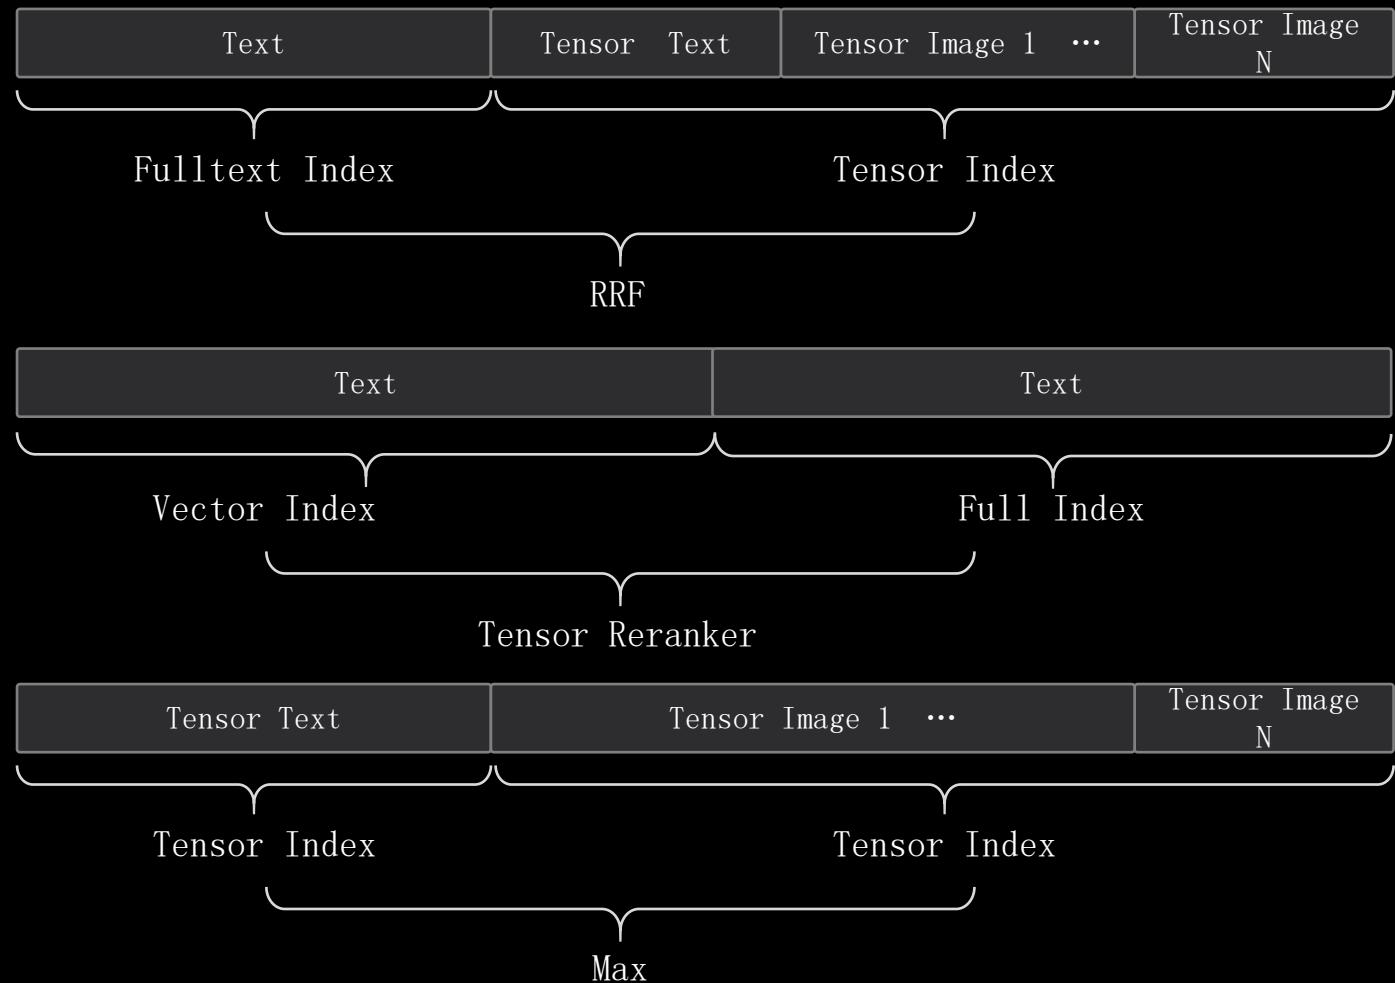
- 图文结合任务优势显著
- 单向量检索存在瓶颈

关于多模态和跨模态 Retrieval 的工程挑战

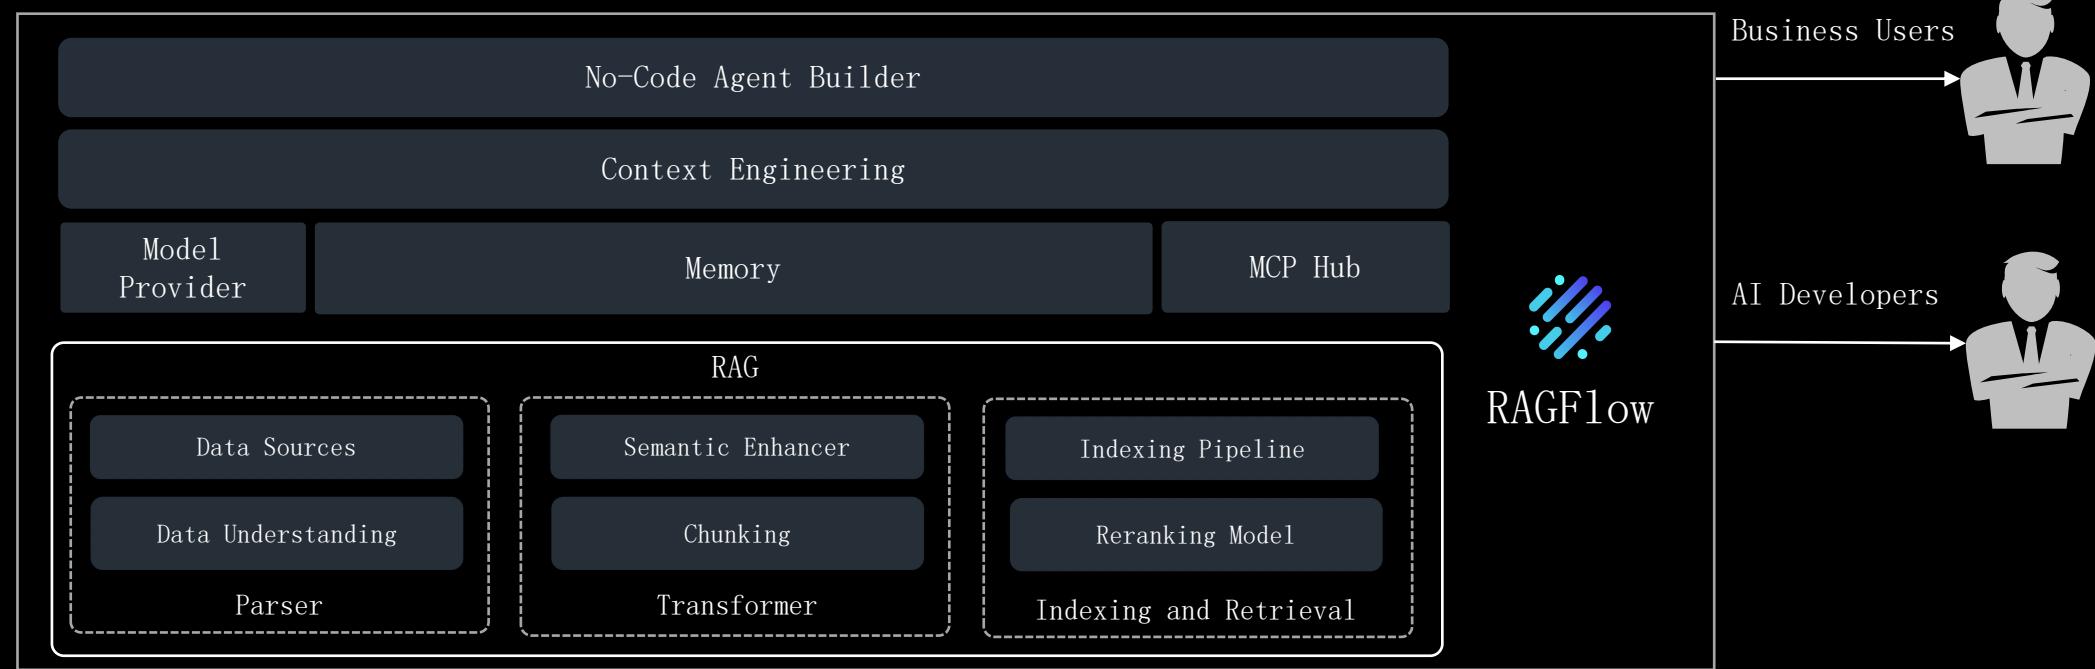


➤ 工程化挑战

- 召回单元
- 存储膨胀/计算复杂度
- 训练对二值量化友好的 Embedding
- Token 剪枝
 - MUVERA
 - Token Clustering
 - 改造VLM，根据注意力分布输出剪枝结果
 - 重新训练，直接在Tokenizer输出少的Token (ModernVBERT)



RAG is Dead? Long Live RAG !





开源社
kaiyuanshe



COSCon'25

第十届中国开源年会

众智开源 | Open Source, Open Intelligence

Thanks

