



COSCon'25

第十届中国开源年会

众智开源 | Open Source, Open Intelligence


开源 AI大模型的合规与安全风险

王永雷 /Black Duck 高级软件安全架构师



CONTENTS

- 01 开源大模型的现状
- 02 欧盟AI Act和 CRA
- 03 如何应对挑战
- 04 Q&A




PART 01

开源大模型的现状



大模型的组成



The screenshot shows a GitHub repository interface. On the left, a list of files is displayed:

- README.md (5.27 kB)
- config.json (878 Bytes)
- configuration_exaone.py (10.5 kB)
- generation_config.json (132 Bytes)
- merges.txt (1.22 MB)
- model-00001-of-00007.safetensors (4.93 GB)
- model-00002-of-00007.safetensors (5 GB)
- model-00003-of-00007.safetensors (5 GB)
- model-00004-of-00007.safetensors (4.83 GB)
- model-00005-of-00007.safetensors (4.83 GB)
- model-00006-of-00007.safetensors (4.83 GB)
- model-00007-of-00007.safetensors (1.68 GB)
- model.safetensors.index.json (23.7 kB)
- modeling_exaone.py (563 Bytes)
- special_tokens_map.json

A blue box highlights the "Model parameters" section, which contains the first seven safetensors files. Another blue box highlights the "Model" section, which contains the remaining files. To the right, a preview of the dataset files is shown:

Preview of files found in this repository

File	Size	Type	Action
train-00000-of-00075.parquet	80.5 MB	LFS	Download
train-00001-of-00075.parquet	79.8 MB	LFS	Download
train-00002-of-00075.parquet	80.5 MB	LFS	Download
train-00003-of-00075.parquet	80.2 MB	LFS	Download
train-00004-of-00075.parquet	79.1 MB	LFS	Download
train-00005-of-00075.parquet	79.6 MB	LFS	Download
train-00006-of-00075.parquet	79.5 MB	LFS	Download
train-00007-of-00075.parquet	80.6 MB	LFS	Download
train-00008-of-00075.parquet	80.5 MB	LFS	Download
train-00009-of-00075.parquet	79.9 MB	LFS	Download
train-00010-of-00075.parquet	79.6 MB	LFS	Download
train-00011-of-00075.parquet	80.0 MB	LFS	Download
train-00012-of-00075.parquet	79.9 MB	LFS	Download
train-00013-of-00075.parquet	79.9 MB	LFS	Download
train-00014-of-00075.parquet	79.9 MB	LFS	Download

Dataset

开源大模型的开源情况



Model	Model/Weights	DataSets	Comments
Qwen3-Omni	Apache 2.0	无公开专属许可，训练数据含公开合规语料	2025 年登顶 Hugging Face 开源榜单的全模态模型，支持文本、图像、音频、视频处理，许可宽松可无限制商用，衍生模型超 9 万个
Qwen2.5 - MAX（阿里通义）	Apache 2.0	无公开专属许可，覆盖 119 种语言的公开数据源	中文语义理解优化突出，支持东南亚多语种，开源生态活跃，适合跨境电商等商用场景，许可无商用门槛
DeepSeek-R1	MIT	无公开专属许可，未披露完整数据集细节	开源模型性能标杆,MIT 许可下商用无额外门槛，仅未公开训练数据集全貌
DeepSeek 其他系列	自定义商业友好许可证	无公开专属许可，未披露完整数据集细节	除 R1 系列外，算法和权重许可禁止军事用途等场景；数据集未开放许可，且未公开训练数据的具体来源与授权细节。
LLaMA 4（Meta）	Llama 4 Community License	无公开专属许可，训练数据含 200 种语言的公开语料	采用混合专家架构，包含 Maverick 和 Scout 两个版本，许可为 Meta 自定义，商用需遵守社区许可条款，对学术研究友好
StableLM Alpha	CC BY - NC - SA 4.0	CC BY - NC - SA 4.0（仅非商用）	算法、权重与数据集均受非商业许可限制；数据集是基于“堆”扩展的 1.5 万亿 token 实验性数据集，微调模型仅限研究使用，商用需替换无限制数据集。

开源大模型的安全事件-供应链攻击：开源生态的“特洛伊木马”



攻击者通过篡改开源代码库、模型仓库或依赖项，将恶意代码植入软件供应链。

攻击途径：

- PyPI/conda 等包管理器上传恶意版本
- Hugging Face 等模型平台植入后门模型
- 修改开源代码库后提交恶意 PR
- 劫持模型命名空间，在可信名称下部署恶意模型

Date	Incidents	Comments
2023/03	Meta LLaMA 泄露	研究团队模型意外公开，引发安全风险，后被用于开发多款闭源商业模型
2024 /12	YOLOv11 投毒事件	v8.3.41 和 v8.3.42 版本被植入加密挖矿软件，下载量超 96 万，用户设备被感染
2025 / 2	Hugging Face 平台 "nullifAI" 攻击	攻击者利用 "损坏的 pickle 文件" 技术绕过安全检测，上传含恶意代码的模型，可收集用户设备信息
2025 / 8	Nx 构建工具被黑	植入恶意代码，主动调用本地 AI 工具窃取信息，攻击数百万开发者

PART 02

欧盟AI Act和CRA法规





监管的要求

通用人工智能模型（GPAI）

通用人工智能模型（GPAI）具备广泛应用能力，是能够在多种任务中表现出色的开源基础模型。如LLaMA 3凭借其在自然语言处理方面的强大能力，可应用于文本生成、智能问答等多个领域；Qwen 2.5也在语言理解和生成上有着卓越表现，能为用户提供高质量的语言交互服务。

系统性风险通用AI模型（GPAISR）

- 训练累计计算量：当模型训练累计计算量 $\geq 10^{25}$ FLOPS 时，其强大的计算能力和广泛的数据处理范围可能引发不可控的风险，因此被视为GPAISR的判定标准之一。
- 顶尖能力与关键领域影响：若模型经评估具备“顶尖能力”，并对医疗、金融、司法等关键领域产生影响，因其决策可能直接关系到人们的生命健康、财产安全和社会公平正义，所以也符合GPAISR判定标准。
- 欧盟AI办公室综合认定：欧盟AI办公室依据专业的评估体系和丰富的经验，对模型进行全面审查和综合考量，若认定某模型具有系统性风险，则将其归为GPAISR。

欧盟 AI ACT 法案开源大模型透明度要求细则

算法·权重·数据集报备要求全解析




开源社
kaiyuanshe

要求类型	普通开源 GPAI 模型	开源 GPAISR 模型	Comments
算法(架构)报备	<input checked="" type="checkbox"/> 豁免(已公开即可)	<input type="checkbox"/> 不豁免(必须报备完整说明)	
权重参数报备	<input checked="" type="checkbox"/> 豁免(已公开即可)	<input type="checkbox"/> 不豁免(必须公开全部权重)	
数据集完整报备	<input type="checkbox"/> 不要求(仅需摘要)	<input type="checkbox"/> 不要求(仅需摘要)	<ul style="list-style-type: none">• 数据来源与收集方式• 版权内容占比• 数据多样性指标• 敏感数据使用情况
数据集摘要报备	<input checked="" type="checkbox"/> 必须(使用官方模板)	<input checked="" type="checkbox"/> 必须(更详细, 需向 AI 办公室报备)	
模型文档表填写	<input checked="" type="checkbox"/> 豁免	<input type="checkbox"/> 不豁免(必须填写并保存 10 年)	

- 软件：如ISV
- 硬件：如IoT设备、智能手机、计算机
- 服务：如基于云平台远程控制智能家居设备

所有“带有数字元素的产品”（PDE）
包括任何软件或硬件及其远程数据处理方案



- 几乎所有具备联网等数字化功能的电子类产品，包括电视、冰箱、智能音响等
- IoT是典型的适用领域
- AI模型

安全设计

- 产品必须在安全的开发生命周期内开发 //**S-SDLC**
- 要确保对存储和传输中的数据进行强加密
- 实施安全启动过程以在执行前验证软件完整性
- 设计产品时要尽量减少攻击面并防止篡改

漏洞处理与事件报告

- 制造商必须有管理漏洞流程，包括：定期更新和打补丁；检测到“任何被大肆利用的漏洞”后**24h**内向欧盟网络安全局（ENISA）披露

SBOM与技术文档

- 制造商必须准备并维护全面的技术文档以证明合规
- 需维护最新的软件物料清单（**SBOM**），列出代码库中所有开源代码组件和依赖、第三方和自有组件及依赖项等信息

更新与维护


- 制造商必须确保在产品预期寿命内提供安全更新并给予支持

用户说明

- 必须向用户提供清晰易懂的信息，说明产品使用中网络安全的相关风险
- 产品必须有标签，告知用户有关网络安全功能及其更新情况

PART 03

如何应对挑战思考



LLM-Risk Management

AI Model Risk

AI model Risk Management

Security and License

Compliance management

Security

Compliance

Operational

Manage and deliver AIBOMs

AI SBOM Up and Down Stream

Third party AIBOM Import

Export AIBOM

Know what's in your code
(AIBOM)

Software Composition Analysis (SCA)

AI Model

AI Weight

DataSets

AI ACT合规行动清单



Model	Action List	Comments
普通开源 GPAI 模型	<ol style="list-style-type: none">1: 验证开源许可类型（确保满足豁免要件）2: 公开模型架构、权重、使用说明 步骤3: 按欧盟模板编制并公开训练数据摘要 步骤4: 留存合规证明文件（许可文本、公开记录）	<ul style="list-style-type: none">• 核心原则：差异化合规，不搞“一刀切”普通开源模型：公开 = 合规，仅需补充数据摘要• 开源 GPAISR：全流程报备，无豁免空间• 关键边界：开源 ≠ 免合规，数据摘要公开是“硬要求”
开源 GPAISR 模型	<ol style="list-style-type: none">1: 提前向欧盟 AI 办公室报备技术文档（算法 + 权重 + 数据摘要）2: 签署《通用人工智能行为准则》（准强制要求）3: 建立风险监测与事件报告机制（24 小时重大事件上报）4: 接受第三方独立评估	<ul style="list-style-type: none">• 实操优先级：先判定风险等级 → 再验证豁免条件 → 最后落实对应要求• 长期关注：欧盟动态调整（如风险阈值、模板内容更新）

供应链合规管理

- 生成标准化 SBOM 并开展第三方依赖尽职调查。
- 建立组件更新淘汰机制





漏洞管理体系的搭建

- 制定透明漏洞披露政策和修复机制。
- 接入开源漏洞共享平台同步威胁情报



披露政策制定

建立公开透明的漏洞披露流程，明确报告渠道与响应时限。



快速修复机制

设定漏洞分级响应标准，确保高危漏洞在规定时间内修复。



威胁情报同步


接入主流开源漏洞库，实时获取并共享最新安全威胁信息。



协同响应网络

与社区及第三方平台联动，提升漏洞处置效率与覆盖范围。

PART 04 Q&A





COSCon'25

第十届中国开源年会

众智开源 | Open Source, Open Intelligence

Thanks

王永雷

